УДК 004.056

РАЗРАБОТКА ЛОКАЛЬНО-ОРИЕНТИРОВАННОЙ СИСТЕМЫ ЗАЩИТЫ ПЕРСОНАЛЬНЫХ ДАННЫХ ПРИ ВЗАИМОДЕЙСТВИИ С МОДЕЛЯМИ ИСКУССТВЕННОГО ИНТЕЛЛЕКТА

Карденас Д.Ф.
Балтийский федеральный университет имени Иммануила Канта
dkardenasnino@stud.kantiana.ru
+7 911 863 26 45

Ключевые слова: защита персональных данных, клиентская предварительная фильтрация, браузерное расширение, генеративные модели искусственного интеллекта, локальная обработка данных.

Аннотация. В работе представлена локально-ориентированная система защиты персональных данных при взаимодействии с облачными моделями искусственного интеллекта. Реализована архитектура браузерного расширения, обеспечивающего обнаружение и нейтрализацию конфиденциальной информации до её передачи во внешние сервисы. Экспериментальное сравнение с облачной фильтрацией показало снижение временных задержек и повышение управляемости обработки данных.

Development of a Local-Oriented System for Personal Data Protection in Interaction with Artificial Intelligence Models. Cardenas D.F. Immanuel Kant Baltic Federal University.

Keywords: personal data protection, client-side filtering, browser extension, generative AI models, local processing.

Abstract. The paper presents a local-oriented system for personal data protection in interaction with cloud-based artificial intelligence models. The architecture of a browser extension providing detection and neutralization of confidential information before its transmission to external services is implemented. Experimental results confirm the reduction of processing delays and increased controllability of data handling compared to cloud-based filtering approaches.

Введение

В последние годы наблюдается интенсивное развитие генеративных моделей искусственного интеллекта [1], включая большие языковые модели, применяемые в образовательной, научной и профессиональной деятельности [2, 5]. Пользователи взаимодействуют с такими системами преимущественно через веб-интерфейсы, передавая текстовые запросы различного содержания. При этом в составе передаваемой информации нередко присутствуют персональные данные, служебные сведения и иные конфиденциальные фрагменты текста.

Несмотря на наличие нормативных актов в области защиты информации и международных стандартов обработки персональных данных [3, 4], конечный пользователь публичных ИИ-сервисов фактически не контролирует состав передаваемых данных. В случае отсутствия предварительной фильтрации электронные адреса, номера телефонов, банковские реквизиты, токены доступа, API-ключи и иные чувствительные элементы могут быть переданы во внешнюю инфраструктуру и сохранены на стороне сервера. Большинство существующих решений ориентировано на серверную фильтрацию или корпоративные шлюзы безопасности, что ограничивает возможности индивидуального пользователя.

В условиях массового использования облачных генеративных платформ возникает необходимость создания инструмента, функционирующего непосредственно на стороне клиента и обеспечивающего предварительную обработку текстовой информации до её передачи внешнему сервису. Цель настоящего исследования заключается в разработке и экспериментальной оценке локально-ориентированной системы автоматического обнаружения и нейтрализации конфиденциальных данных в текстовых запросах пользователей при взаимодействии с облачными моделями искусственного интеллекта.

Архитектура системы

Разработанная система реализована в виде браузерного расширения, функционирующего в среде современных веб-браузеров на базе Chromium. Архитектура решения построена по модульному принципу и включает компонент перехвата пользовательского ввода (content script), модуль обнаружения конфиденциальной информации, модуль нейтрализации данных и механизм локального хранения соответствий. Обработка текстовой информации осуществляется исключительно на стороне клиента, что исключает передачу исходных данных во внешнюю инфраструктуру до завершения процедуры фильтрации.

Общая структура взаимодействия компонентов представлена на рис. 1. При вводе пользователем текста в веб-интерфейсе облачной модели активируется встроенный в страницу сценарий, осуществляющий перехват содержимого поля ввода перед отправкой запроса. Далее текст передается во внутренний движок анализа, где выполняется последовательная проверка на наличие шаблонов, соответствующих форматам персональных данных. Такой подход позволяет интегрировать систему непосредственно в процесс взаимодействия пользователя с веб-приложением без изменения логики работы внешнего сервиса.

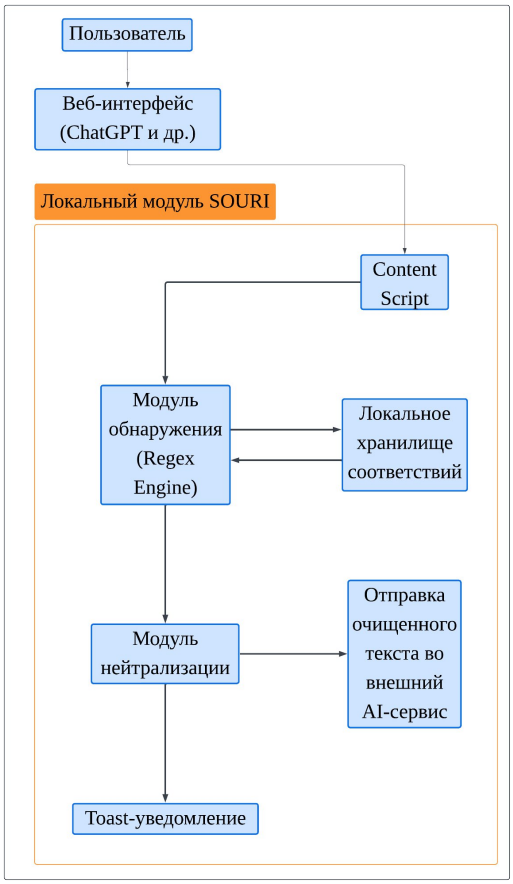

Рисунок 1 – Архитектура локально-ориентированной системы защиты данных

Модуль обнаружения и модуль нейтрализации логически разделены, что обеспечивает гибкость и расширяемость архитектуры. Движок обнаружения отвечает за идентификацию потенциально чувствительных фрагментов текста, тогда как модуль нейтрализации выполняет их замену на унифицированные маркеры. Соответствия между исходными значениями и маркерами сохраняются в локальном хранилище браузера с использованием стандартных механизмов client-side storage, что обеспечивает обратимость преобразования при необходимости восстановления исходного текста.

Выбранная архитектурная модель ориентирована на минимизацию вычислительной нагрузки и исключение сетевых задержек, связанных с передачей данных на внешние серверы для предварительной обработки. Локализация анализа позволяет снизить риски утечки информации и повысить прозрачность функционирования системы для конечного пользователя.

Алгоритмы обнаружения и нейтрализации информации

В основе функционирования разработанной системы лежит последовательный алгоритм анализа текстовой информации, направленный на выявление потенциально конфиденциальных фрагментов до момента передачи данных во внешний сервис. Логика обработки включает этап перехвата пользовательского ввода, последующее сканирование содержимого и выполнение процедуры замещения обнаруженных элементов. Общая схема алгоритма представлена на рис. 2.

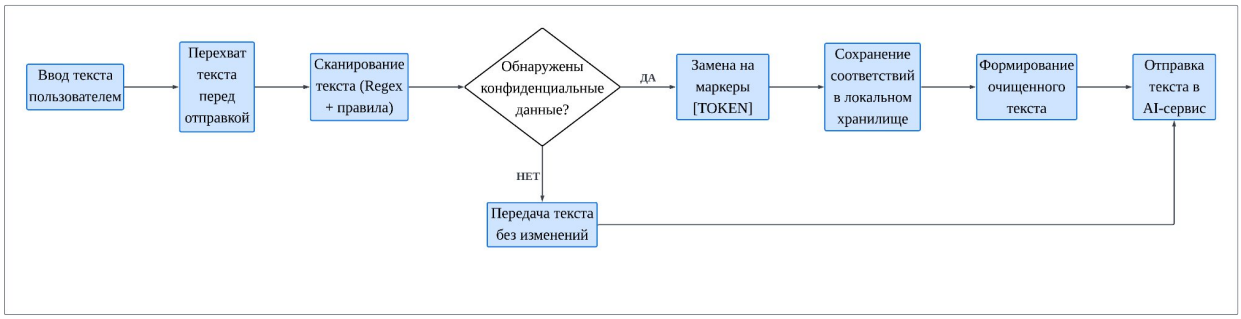

Рисунок 2 – Блок-схема алгоритма обнаружения и нейтрализации конфиденциальной информации

Основным инструментом детекции являются регулярные выражения, позволяющие идентифицировать стандартизированные форматы персональных данных, такие как адреса электронной почты, телефонные номера, банковские реквизиты, токены авторизации и API-ключи. Дополнительно применяется проверка структуры строки, длины фрагмента и характерных префиксов, что позволяет повысить точность распознавания и снизить вероятность ложных срабатываний.

После завершения этапа обнаружения формируется список совпадений с указанием позиции каждого фрагмента в исходном тексте. Далее выполняется их замещение унифицированными маркерами, при этом соответствие между исходным значением и маркером сохраняется в локальном хранилище браузера. Такой подход обеспечивает обратимость преобразования и позволяет при необходимости восстановить исходные данные без их передачи на сторонние серверы.

Алгоритм реализован с учетом требования линейной вычислительной сложности, что обеспечивает пропорциональный рост времени обработки при увеличении объема текста. Отсутствие обращения к внешним ресурсам на этапе предварительной фильтрации минимизирует сетевые задержки и повышает устойчивость функционирования системы.

Анализ представленной блок-схемы показывает, что разработанный алгоритм реализует последовательную модель обработки данных без возврата к предыдущим этапам, что обеспечивает детерминированность и предсказуемость поведения системы. Условный оператор проверки наличия конфиденциальных данных формирует две возможные ветви выполнения: передачу текста без изменений либо его предварительную модификацию с сохранением соответствий. Такое построение логики позволяет минимизировать избыточные вычисления и избежать повторного анализа уже обработанных фрагментов.

Особенностью алгоритма является локальный характер всех операций, включая хранение промежуточных результатов. Отсутствие сетевого взаимодействия на этапе предварительной фильтрации исключает влияние внешних факторов на стабильность функционирования системы и обеспечивает постоянство временных характеристик обработки.

Методика экспериментального исследования была направлена на количественную оценку производительности разработанной локально-ориентированной системы по сравнению с облачным механизмом предварительной фильтрации данных. Эксперименты проводились в среде браузера Google Chrome (версия на базе Chromium) на персональном компьютере со стандартной конфигурацией пользовательского уровня. Для измерения времени обработки использовались встроенные средства профилирования JavaScript и функции высокоточного таймера performance.now().

В рамках эксперимента формировались текстовые фрагменты различной длины — от 500 до 5000 символов — содержащие как обычный текст, так и фрагменты, соответствующие шаблонам конфиденциальной информации. Для каждого объема текста выполнялось не менее десяти повторных измерений с последующим вычислением среднего значения времени обработки. Это позволило снизить влияние случайных колебаний и обеспечить сопоставимость результатов.

Для облачной архитектуры учитывалось суммарное время, включающее передачу запроса на внешний сервер, серверную обработку и возврат результата. Таким образом, в эксперименте оценивалась не только вычислительная сложность алгоритмов, но и влияние сетевой задержки на общую производительность системы.

Результаты и обсуждение

Полученные экспериментальные данные демонстрируют устойчивую зависимость времени обработки текста от его длины при использовании двух архитектур — локальной и облачной. В ходе эксперимента измерялось среднее время предварительной фильтрации текстовых фрагментов различного объема.

Для локально-ориентированной системы зафиксирован линейный характер роста временных затрат по мере увеличения длины входного текста, что соответствует ожидаемой вычислительной сложности алгоритма. В случае облачной архитектуры уже при малых объемах данных наблюдается более высокий уровень задержки, связанный с необходимостью передачи запроса на внешний сервер и ожидания ответа.

Сравнительный график зависимости времени обработки от длины текста представлен на рис. 3.

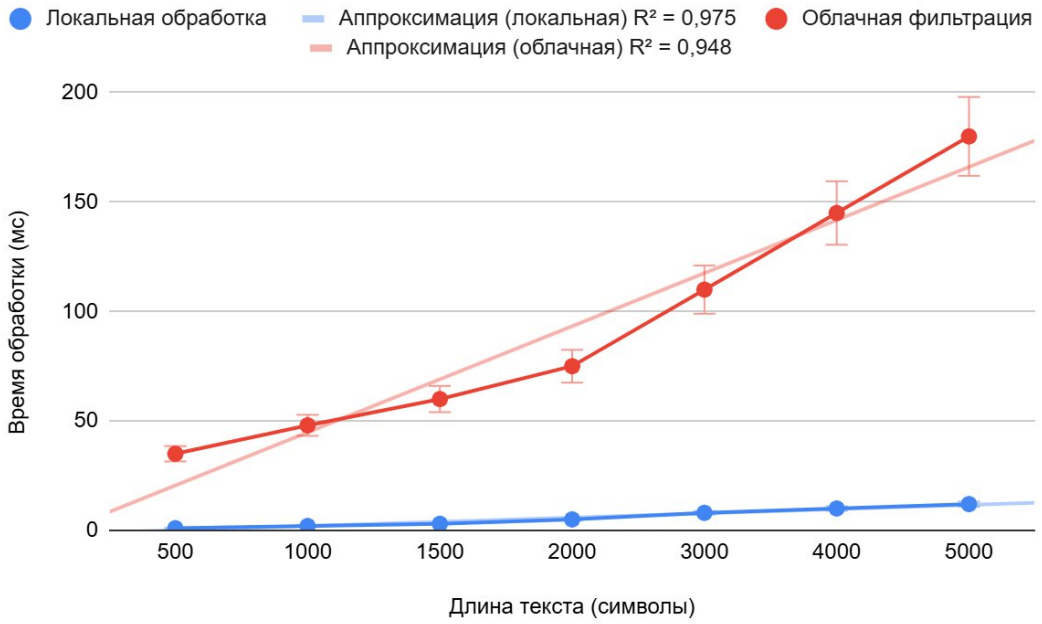

Рисунок 3 – Сравнение времени обработки текста при локальной и облачной предварительной фильтрации данных.

Анализ представленных данных показывает, что локально-ориентированная архитектура обеспечивает существенно меньшие временные затраты по сравнению с облачным механизмом предварительной фильтрации. Разница становится особенно заметной при увеличении объема текста, где влияние сетевой задержки становится доминирующим фактором для облачной модели обработки.

Линейная аппроксимация экспериментальных данных подтверждает устойчивый характер роста временных затрат в обоих случаях, однако коэффициент наклона для облачной архитектуры значительно выше, что указывает на меньшую масштабируемость данного подхода.

Отсутствие сетевого взаимодействия в локальной системе обеспечивает стабильность временных характеристик и снижает вариативность, связанную с состоянием канала передачи данных. Это повышает предсказуемость работы алгоритма и управляемость процесса обработки.

Таким образом, результаты эксперимента подтверждают целесообразность переноса этапа предварительной фильтрации конфиденциальной информации на сторону клиента. Локализация данного этапа позволяет сократить задержки, повысить контроль пользователя над передаваемыми данными и минимизировать риск непреднамеренной утечки информации.

Следует отметить, что исследование проводилось на основе типовых шаблонов конфиденциальных данных. В перспективе возможно расширение алгоритма за счет внедрения методов контекстного анализа без существенного увеличения вычислительной нагрузки.

Выводы

Разработана локально-ориентированная система защиты персональных данных при взаимодействии с облачными моделями искусственного интеллекта. Экспериментально подтверждено снижение времени

обработки при использовании клиентской предварительной фильтрации по сравнению с облачной архитектурой. Локализация анализа позволяет уменьшить влияние сетевых задержек и повысить контроль пользователя над передаваемой информацией. Полученные результаты демонстрируют практическую эффективность предложенного подхода.

Список использованных источников

1. Russell S., Norvig P. *Artificial Intelligence: A Modern Approach*. – 4th ed. – Boston: Pearson, 2020. – 1136 p.
2. Goodfellow I., Bengio Y., Courville A. *Deep Learning*. – Cambridge: MIT Press, 2016. – 775 p.
3. Regulation (EU) 2016/679 of the European Parliament and of the Council of 27 April 2016 on the protection of natural persons with regard to the processing of personal data (General Data Protection Regulation) // *Official Journal of the European Union*. – 2016.
4. ISO/IEC 27001:2022 Information security, cybersecurity and privacy protection — Information security management systems — Requirements. – Geneva: ISO, 2022.
5. Vaswani A., Shazeer N., Parmar N. et al. Attention Is All You Need // *Advances in Neural Information Processing Systems*. – 2017. – Vol. 30. – P. 5998–6008.